Projet SMS Spam Filtering

Rushan Zamir Saeedullah & Berville Laurence

Introduction :

Analyse du besoin

Le service de messages courts (SMS) est le service de communication textuelle des systèmes de communication téléphonique, qu'un utilisateur peut utiliser pour communiquer avec d'autres utilisateurs. L'inconvénient, c'est que les téléphones portables sont en train de devenir la dernière cible du courrier électronique indésirable, avec un nombre croissant d'annonceurs à utiliser les messages texte pour cibler leurs abonnés. Pour le consommateur, le spam est un message indésirable, parfois répété, qui vise généralement à le tromper et à lui soutirer de l'argent par le biais d'une communication payante.

Un modèle de prédiction en Python est un algorithme mathématique utilisé pour faire des prédictions ou des prévisions basées sur des données d'entrée. Il utilise l'apprentissage automatique ou des techniques statistiques pour analyser des données historiques et apprendre des modèles, qui peuvent ensuite être utilisés pour prédire des résultats ou des tendances futurs.

Nous allons présenter ici nos travaux qui consistent en l'exploitation d'une base de donnée SMS, puis par la construction d'une application de détection de spam. Voici les étapes :

- Exploration de la base de donnée SMS,
- Construction d'un pipeline de ML,
- Prétraitement des données,
- Entrainement, fine tuning,
- Et validation et sélection d'un modèle de classification.

Mise en place de l'environnement

- Acquisition des données et mise en forme

1- Une collection de 425 messages de spam SMS a été extraite manuellement du site web Grumbletext. Il s'agit d'un forum britannique dans lequel les utilisateurs de téléphones portables font des déclarations publiques sur les messages de spam SMS, la plupart du temps sans signaler l'incident.

2- Egalement inclus dans le dataset, un sous-ensemble de 3 375 SMS, choisis au hasard dans le corpus NUS SMS, qui est un ensemble de données d'environ 10 000 messages légitimes collectés pour la recherche au département d'informatique de l'université nationale de Singapour. Les messages proviennent en grande partie de Singapouriens et surtout d'étudiants de l'université. Ces messages ont été collectés auprès de volontaires qui ont été informés que leurs contributions allaient être rendues publiques.

3- Une liste de 450 SMS spam recueillis dans la thèse de doctorat de Caroline Tag, disponible à l'adresse http://etheses.bham.ac.uk/253/1/Tagg09PhD.pdf.

4- Enfin, nous avons intégré le corpus SMS Spam v.0.1 Big. Il contient 1 002 SMS ham et 322 messages de spam et est accessible au public à l'adresse suivante : http://www.esp.uem.es/jmgomez/smsspamcorpus/.

- Pour ce projet, nous allons utiliser les packages ci-dessous :

```
import matplotlib.pyplot as plt # Graphiques
import seaborn as sns # Graphiques

from sklearn.pipeline import Pipeline # pour faire un pipeline
from sklearn.model_selection import train_test_split # pour diviser le dataset en training data set
from sklearn.feature_extraction.text import TfidfVectorizer # pour vectoriser les messages en matrice
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix, ConfusionMatrixDisplay

import pandas as pd # Gestion des dataframes
```

```
import numpy as np # Gestion des datasframes

import nltk# Preprocessing pour enlever ponctuation - Natural Language Processing
nltk.download("punkt")
nltk.download('stopwords')
from nltk.corpus import stopwords # Preprocessing pour enlever les mots "courant"

import string # pour enlever les listes

import warnings
warnings.filterwarnings('ignore') # enlever les warnings de python
```

- Récupération des données :

```
data = pd.read_csv('https://raw.githubusercontent.com/remijul/dataset/master/SMSSpamCollection',
         sep='\t', header=None)
```

- Renommer les colonnes :

Les données téléchargées consistent en 2 colonnes. Une avec la définition des messages comme "Spam" ou "Ham", renommée "Target". La seconde colonne contient le message, renommer "SMS".

```
data=data.rename(columns={0:"Target",1:"SMS"}) # Renommer les colonnes.
```

Exploration de la base de donnée

- Répartition des variables dans le data set.

Dans les éléments suivants nous présentons quelques statistiques descriptives de l'ensemble de données.

En résumé, le dataset est composé de 4 825 messages légitimes et de 747 messages de spam mobile, soit un total de 5 572 messages. Nous constatons une forte disproportion entre les deux variables.

```
Ratio=data['Target'].value_counts()
Ratio= pd.DataFrame(Ratio)
Ratio
```

	Target int64
ham	4825
spam	747

2 rows, showing 5 per page « ‹ Page 1 of 1 › »

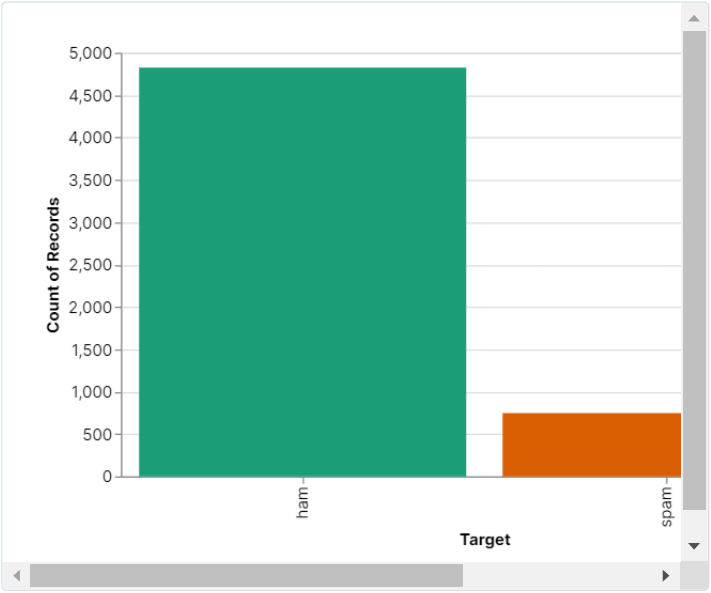

- Les doublons :

Nous créons deux sous tableaux avec les données Ham et les données Spams. Puis, nous observons les messages.

```
HamData = data[data['Target'] == "ham"]
print(HamData.head(5))
```

```
  Target                                                SMS
0    ham  Go until jurong point, crazy.. Available only ...
1    ham                      Ok lar... Joking wif u oni...
3    ham  U dun say so early hor... U c already then say...
```

```
SpamData = data[data['Target'] == "spam"]
print(SpamData.head(5))
```

```
   Target                                                SMS
2    spam  Free entry in 2 a wkly comp to win FA Cup fina...
5    spam  FreeMsg Hey there darling it's been 3 week's n...
8    spam  WINNER!! As a valued network customer you have...
```

4	ham	Nah I don't think he goes to usf, he lives aro...
6	ham	Even my brother is not like to speak with me. ...

9	spam	Had your mobile 11 months or more? U R entitle...
11	spam	SIX chances to win CASH! From 100 to 20,000 po...

Pour compter les spams et les observer.

```
HamData_counts= pd.DataFrame(HamData['SMS'].value_counts())# il y
HamData_counts
```

	SMS int64 1 - 30
Sor...	30
I ca...	12
Ok...	10
Ok	4
Yo...	4
7 w...	4
We...	4
Ok.	4
Okie	4
Say...	4

4516 rows, showing 10 per page Page 1 of 452

```
SpamData_counts= pd.DataFrame(SpamData['SMS'].value_counts())# il
SpamData_counts
```

	SMS int64 1 - 4
Ple...	4
Ca...	3
FR...	3
HM...	3
I d...	3
Loa...	3
Su...	2
Yo...	2
Urg...	2
Wa...	2

653 rows, showing 10 per page Page 1 of 66

Il y a par exemple 30 messages identiques dans les "Hams".

Avec".describe", nous pouvons observer les statistiques descriptives :

```
HamData_counts.describe()
```

	SMS float64
cou...	4516
me...	1.068423384
std	0.5635391201
min	1
25%	1
50%	1
75%	1
max	30

8 rows, showing 10 per page Page 1 of 1

```
SpamData_counts.describe()
```

	SMS float64
cou...	653
me...	1.143950995
std	0.3846530714
min	1
25%	1
50%	1
75%	1
max	4

8 rows, showing 10 per page Page 1 of 1

Nous pouvons émettre trois hypothèses, à propos de la présence des doublons.

1- Comme nous l'avons noté dans l'introduction, il y a plusieurs datasets qui ont été combinés pour créer un, et donc certains messages sont en double (ou plus).

2- Les messages spams ont été envoyés à plusieurs personnes et ensuite déclarés plusieurs fois par les utilisateurs.

3- Le type de message, comme "ok", et souvent utilisés pas les rédacteurs de sms.

Dans les deux premiers cas, nous considérons que les doublons doivent être retirés, mais pas dans le 3e cas. Dans le pipeline nous allons donc utiliser deux datasets. Un avec les doublons et l'autre sans.

- Nous souhaitons ensuite compter le nombre moyen de mot dans un spam et un ham.

```
HamData["Number of Words"] = HamData["SMS"].apply(
    lambda n: len(n.split()))
mean_Ham = HamData["Number of Words"].mean()
```

```
SpamData["Number of Words"] = SpamData['SMS'].apply(
    lambda n: len(n.split()))
mean_Spam = SpamData["Number of Words"].mean()
```

Explorations graphiques

```
data["Number of Words"] = data["SMS"].apply(lambda n: len(n.split()))

sns.set_theme(style="ticks")# theme de la page.
f, ax = plt.subplots(figsize=(15, 3)) # taille de la page et initialisation de la figure

# Plot the orbital period with horizontal boxes
sns.boxplot(
    data,
    x="Number of Words", #Variable x
     y="Target",  # variable y
     hue="Target",
    whis=[0, 100],
    width=.6, # taille des boxplot
    palette="vlag") # couleurs

# Rajouter les points de chaque observation.
sns.stripplot(data, x="Number of Words",
                y="Target",
                hue= "Target",
                size=3, # taille des points
                palette="vlag", # couleurs des points
                color=".5") # transparence

# Tweak the visual presentation
ax.xaxis.grid(True)# rajouter des grilles en background (x)
ax.set(ylabel="") # pas de titre pour l'axe y
sns.despine(trim=True, left=True)
```

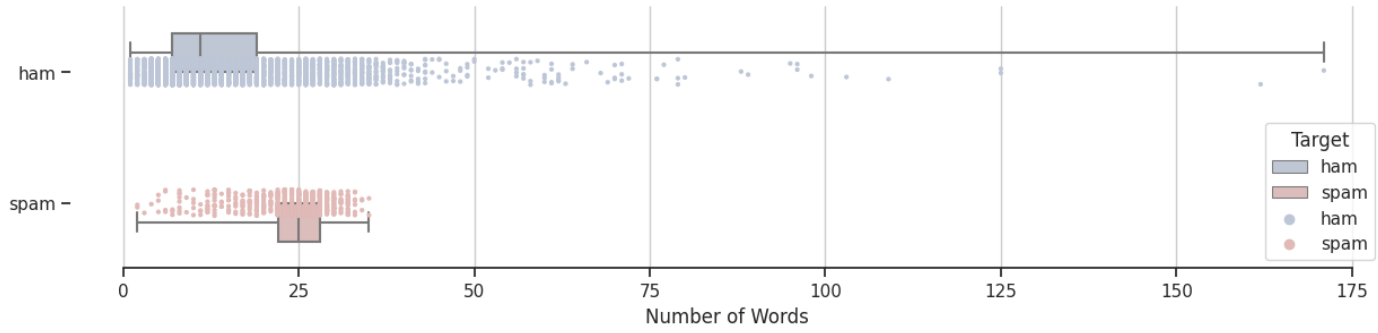

Nous notons que les hams ont des longueurs qui semblent plus variées, mais avec une moyenne plus faible que les spams.

Preprocessing

Enlever la ponctuation et les stopwords.

En recherche d'information, un mot vide (ou stop word, en anglais) est un mot qui est tellement commun qu'il est inutile de l'indexer ou de l'utiliser dans une recherche. En d'autres termes, un mot qui apparaît avec une fréquence semblable dans chacun des textes de la collection n'est pas discriminant car il ne permet pas de distinguer les textes les uns par rapport aux autres. Ex : 'the', 'and', 'l', "a", "an", "the", et "of"

```
stop_words = list(stopwords.words('english'))
print(len(stop_words),stop_words)
```

```
179 ['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you', "yo
```

Nous allons donc enlever 179 stopwords. Puis les ponctuations.

```
print(string.punctuation)
```

```
!"#$%&'()*+,-./:;<=>?@[\]^_`{|}~
```

```
def text_process(text): # pour enlever les mots les plus courants et la ponctuation des messages
    text = text.translate(str.maketrans('', '', string.punctuation))
    text = [word for word in text.split() if word.lower() not in stopwords.words('english')]
    return " ".join(text)
```

```
df= pd.DataFrame(data['SMS'].apply(text_process))
```

```
label = pd.DataFrame(data['Target']) # Colonne avec que les Targets
df= pd.concat([label, df],axis=1)
```

Enlever les doublons

Nous allons enlever les doublons. Puis, compter le nombre de mot dans les messages.

```
df = df.drop_duplicates()# enlever les doublons
```

```
df["Nb_Words"] = df["SMS"].apply(lambda n: len(n.split()))
df.head(5)
```

	Target object	SMS object	Nb_Words int64
0	ham	Go jurong point c...	16
1	ham	Ok lar Joking wif ...	6
2	spam	Free entry 2 wkly...	23
3	ham	U dun say early h...	9
4	ham	Nah dont think g...	8

5 rows, showing 50 per page Page 1 of 1

Déclarer et encoder la target

```
from sklearn.preprocessing import LabelEncoder
lb_encod = LabelEncoder()
y = lb_encod.fit_transform(df['Target'])
```

```
y
```

```
array([0, 0, 1, ..., 0, 0, 0])
```

Déclarer les features

```
X=pd.DataFrame(df['SMS'])
X.head(3)
```

	SMS object
0	Go jurong point c...
1	Ok lar Joking wif ...
2	Free entry 2 wkly...

3 rows, showing 10 per page Page 1 of 1

Conversion de mots en vecteurs : Feature extraction

Nous pouvons convertir les mots en vecteurs en utilisant soit le vecteur de comptage, soit le vecteur TF-IDF.

Le TF-IDF (de l'anglais term frequency-inverse document frequency) est meilleur que les vecteurs de comptage car il ne se concentre pas seulement sur la fréquence des mots présents dans le *corpus*, mais fournit également l'importance des mots. Nous pouvons alors supprimer les mots qui sont moins importants pour l'analyse, ce qui rend la construction du modèle moins complexe en réduisant les dimensions d'entrée.

```
# target preprocessing
tfidf_vectorizer  = TfidfVectorizer(use_idf=False,
                                    lowercase=True,
```

```
                                        strip_accents='ascii')
                                        #,stop_words=stop_words) # enlever les stopwords
```

Train test split

```
X_train, X_test, y_train, y_test = train_test_split(data['SMS'],
                                                    data['Target'],
                                                    test_size=0.20,# 20% test size et 80% train
                                                    random_state=42,
                                                    stratify=data['Target']) #
```

X_train.shape	y_train.shape	y_test.shape	X_test.shape
(4457,)	(4457,)	(1115,)	(1115,)

Modèles

Classification à l'aide de classificateurs de Sklearn

Dans cette étape, nous allons utiliser certains des classificateurs les plus populaires et comparer leurs résultats.

- Classification des spams à l'aide de la régression logistique

```
from sklearn.linear_model import LogisticRegression
```

- Classification des spams à l'aide de SVM

```
from sklearn.svm import SVC
```

- Classification des spams à l'aide de la méthode des bayes naïves

```
from sklearn.naive_bayes import MultinomialNB
```

- Classification des spams à l'aide d'un arbre de décision

```
from sklearn.tree import DecisionTreeClassifier
```

- Classification des spams à l'aide de K-Nearest Neighbor (KNN)

```
from sklearn.neighbors import KNeighborsClassifier
```

- Classification des spams à l'aide d'un Random Forest Classifier.

```
from sklearn.ensemble import RandomForestClassifier
```

Nous allons tester les 6 modèles :

```
svc = SVC(kernel='sigmoid', gamma=1.0)
knc = KNeighborsClassifier(n_neighbors=49)
mnb = MultinomialNB(alpha=0.2)
dtc = DecisionTreeClassifier(min_samples_split=7, random_state=111)
lrc = LogisticRegression(solver='liblinear', penalty='l1')
rfc = RandomForestClassifier(n_estimators=31, random_state=111)
```

Pipelines

Nous déclarons, ci-dessous les 6 modèles :

```
SVC_vectorizer = Pipeline([
     ('vectorizer', tfidf_vectorizer),
     ('classifier', svc)
 ])
```

```
KNC_vectorizer = Pipeline([
     ('vectorizer', tfidf_vectorizer),
     ('classifier',knc )
 ])
```

```
SVC_vectorizer.fit(X_train, y_train)
```

```
KNC_vectorizer.fit(X_train, y_train)
```

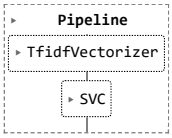

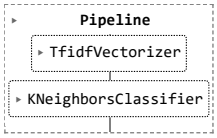


```
MNB_vectorizer = Pipeline([
     ('vectorizer', tfidf_vectorizer),
     ('classifier', mnb)
 ]).fit(X_train, y_train)
```

```
DTC_vectorizer = Pipeline([
     ('vectorizer', tfidf_vectorizer),
     ('classifier', dtc)
 ]).fit(X_train, y_train)
```

```
LRC_vectorizer = Pipeline([
     ('vectorizer', tfidf_vectorizer),
     ('classifier', lrc)
 ]).fit(X_train, y_train)
```

```
RFC_vectorizer = Pipeline([
     ('vectorizer', tfidf_vectorizer),
     ('classifier', rfc)
 ]).fit(X_train, y_train)
```

Prédictions sur les données du X-test set

Nous allons calculer "l'accuracy score" de chaque modèle. L'accuracy permet de décrire la performance du modèle sur les individus positifs et négatifs de façon symétrique. Elle mesure le taux de prédictions correctes sur l'ensemble des individus.

```
y_pred_SVC = SVC_vectorizer.predict(X_test)
print(f"Train Accuracy using Count Vectorizer: {accuracy_score(y_test,y_pred_SVC):.3f}")
```

```
Train Accuracy using Count Vectorizer: 0.979
```

```
y_pred_KNC = KNC_vectorizer.predict(X_test)
print(f"Train Accuracy using Count Vectorizer:{accuracy_score(y_test,y_pred_KNC):.3f}")
```

```
Train Accuracy using Count Vectorizer:0.952
```

```
y_pred_MNB = MNB_vectorizer.predict(X_test)
print(f"Train Accuracy using Count Vectorizer: {accuracy_score(y_test,y_pred_MNB):.3f}")
```

```
Train Accuracy using Count Vectorizer: 0.978
```

```
y_pred_DTC = DTC_vectorizer.predict(X_test)
print(f"Train Accuracy using Count Vectorizer: {accuracy_score(y_test,y_pred_DTC):.3f}")
```

```
Train Accuracy using Count Vectorizer: 0.963
```

```
y_pred_LRC = LRC_vectorizer.predict(X_test)
print(f"Train Accuracy using Count Vectorizer: {accuracy_score(y_test,y_pred_LRC):.3f}")
```

```
Train Accuracy using Count Vectorizer: 0.970
```

```
y_pred_RFC = RFC_vectorizer.predict(X_test)
print(f"Train Accuracy using Count Vectorizer: {accuracy_score(y_test,y_pred_RFC):.3f}")
```

```
Train Accuracy using Count Vectorizer: 0.973
```

Rapports de la classification

Les métriques d'erreurs

La précision et le recall sont deux métriques essentielles en classification, du fait de leur robustesse et de leur interprétabilité. La précision (precision en anglais) et le rappel (recall en anglais) sont deux métriques pour évaluer la performance des modèles de classification à 2 classes ou plus. Ces métriques sont basées sur la matrice de confusion.

La précision est également appelée Positive Predictive Value. Elle correspond au taux de prédictions correctes parmi les prédictions positives. Elle mesure la capacité du modèle à ne pas faire d'erreur lors d'une prédiction positive.

Le recall est également appelé sensitivity (sensibilité), true positive rate ou encore hit rate (taux de détection). Il correspond au taux d'individus positifs détectés par le modèle.

Le F1-score évalue la capacité d'un modèle de classification à prédire efficacement les individus positifs, en faisant un compromis entre la précision et le recall. Le F1-score permet de résumer les valeurs de la précision et du recall en une seule métrique.

```
print(classification_report(y_test, y_pred_SVC))
```

```
              precision    recall  f1-score   support

         ham       0.98      1.00      0.99       966
        spam       0.98      0.87      0.92       149

    accuracy                           0.98      1115
   macro avg       0.98      0.93      0.95      1115
weighted avg       0.98      0.98      0.98      1115
```

```
print(classification_report(y_test, y_pred_KNC))
```

```
              precision    recall  f1-score   support

         ham       0.95      1.00      0.97       966
        spam       1.00      0.64      0.78       149

    accuracy                           0.95      1115
   macro avg       0.97      0.82      0.88      1115
weighted avg       0.95      0.95      0.95      1115
```

```
print(classification_report(y_test, y_pred_MNB))
```

```
              precision    recall  f1-score   support

         ham       0.97      1.00      0.99       966
        spam       1.00      0.83      0.91       149

    accuracy                           0.98      1115
   macro avg       0.99      0.92      0.95      1115
weighted avg       0.98      0.98      0.98      1115
```

```
print(classification_report(y_test, y_pred_DTC))
```

```
              precision    recall  f1-score   support

         ham       0.97      0.98      0.98       966
        spam       0.89      0.83      0.86       149

    accuracy                           0.96      1115
   macro avg       0.93      0.91      0.92      1115
weighted avg       0.96      0.96      0.96      1115
```

```
print(classification_report(y_test, y_pred_LRC))
```

```
              precision    recall  f1-score   support

         ham       0.97      0.99      0.98       966
        spam       0.96      0.81      0.88       149

    accuracy                           0.97      1115
   macro avg       0.97      0.90      0.93      1115
weighted avg       0.97      0.97      0.97      1115
```

```
print(classification_report(y_test, y_pred_RFC))
```

```
              precision    recall  f1-score   support

         ham       0.97      1.00      0.98       966
        spam       1.00      0.80      0.89       149

    accuracy                           0.97      1115
   macro avg       0.98      0.90      0.94      1115
weighted avg       0.97      0.97      0.97      1115
```

Matrices de confusion

Les nombres en diagonale sont liés aux prédictions correctes, tandis que les nombres hors diagonale sont liés aux prédictions incorrectes (mauvaises classifications). Nous connaissons maintenant les quatre types de prédictions correctes et erronées :

Le coin inférieur droit correspond aux vrais positifs (TP), c'est-à-dire aux spam qui ont ont été prédites comme telles par le classificateur;

Le coin supérieur gauche est constitué de vrais négatifs (TN) et correspond aux hams qui ont été prédits comme telles par le classificateur ;

Le coin inférieur gauche correspond aux faux négatifs (FN) et correspond aux spams mais qui ont été prédits comme hams ;

Le coin supérieur droit correspond aux faux positifs (FT) et correspond aux hams mais qui ont été prédits comme spams.

```
cm = confusion_matrix(y_test,y_pred_SVC)
f, ax = plt.subplots(figsize =(5,5))
sns.heatmap(cm,annot = True,
            linewidths=0.6,
            linecolor="black",
            fmt = ".0f",
            cmap="YlGnBu",
            ax=ax)
plt.xlabel("True label")
plt.ylabel("Predicted label")
ax.set_title(' SVC')
plt.show()
```

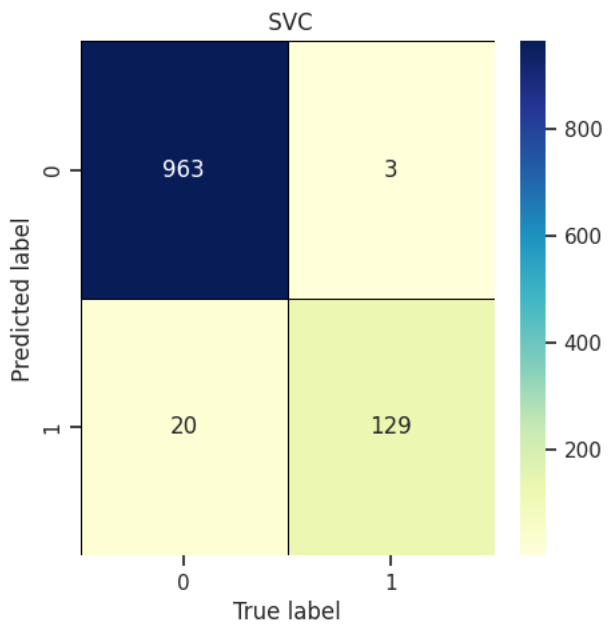


```
cm = confusion_matrix(y_test,y_pred_KNC)
f, ax = plt.subplots(figsize =(5,5))
sns.heatmap(cm,annot = True,
            linewidths=0.5,
            linecolor="black",
            fmt = ".0f",
            cmap="YlGnBu",
            ax=ax)
plt.xlabel("True label")
plt.ylabel("Predicted label")
ax.set_title('KNC')
plt.show()
```

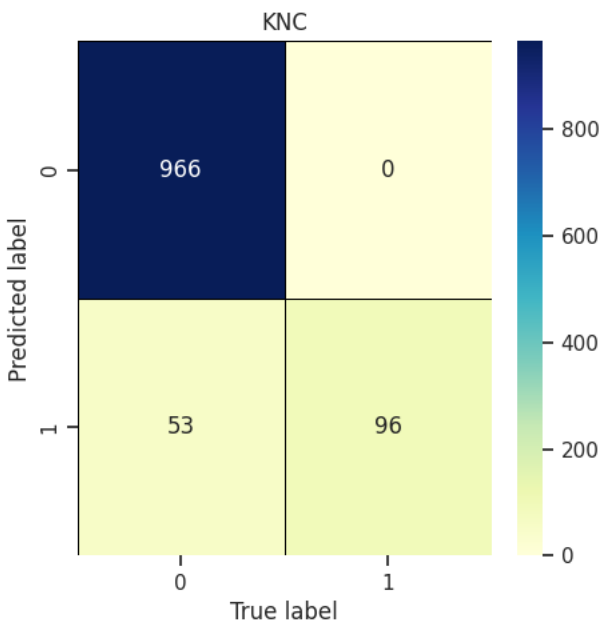


```
cm = confusion_matrix(y_test,y_pred_MNB)
f, ax = plt.subplots(figsize =(5,5))
sns.heatmap(cm,annot = True,
            linewidths=0.5,
            linecolor="black",
            fmt = ".0f",
            cmap="YlGnBu",
            ax=ax)
plt.xlabel("True label")
plt.ylabel("Predicted label")
ax.set_title('MNB')
plt.show()
```

```
cm = confusion_matrix(y_test,y_pred_DTC)
f, ax = plt.subplots(figsize =(5,5))
sns.heatmap(cm,annot = True,
            linewidths=0.5,
            linecolor="black",
            fmt = ".0f",
            cmap="YlGnBu",
            ax=ax)
plt.xlabel("True label")
plt.ylabel("Predicted label")
ax.set_title(' DTC')
plt.show()
```

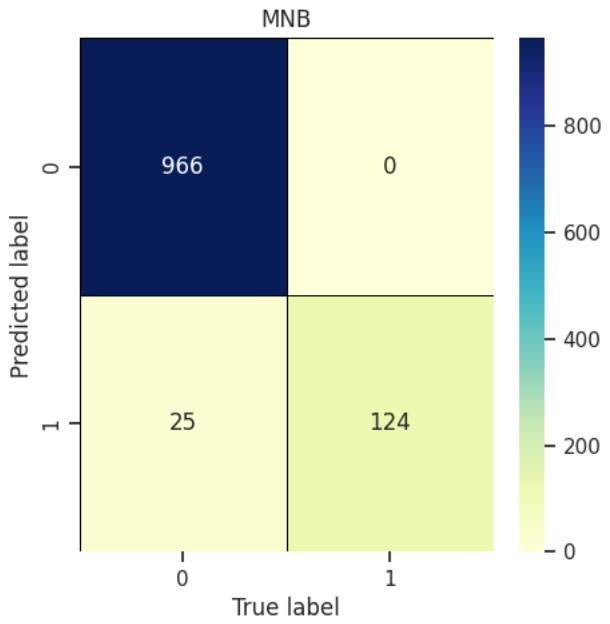

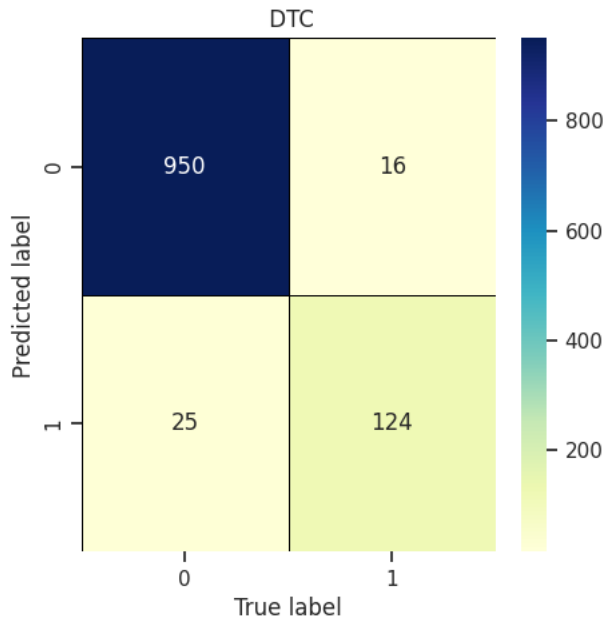


```
cm = confusion_matrix(y_test,y_pred_LRC)
f, ax = plt.subplots(figsize =(5,5))
sns.heatmap(cm,annot = True,
            linewidths=0.5,
            linecolor="black",
            fmt = ".0f",
            cmap="YlGnBu",
            ax=ax)
plt.xlabel("True label")
plt.ylabel("Predicted label")
ax.set_title('LRC')
plt.show()
```

```
cm = confusion_matrix(y_test,y_pred_RFC)
f, ax = plt.subplots(figsize =(5,5))
sns.heatmap(cm,annot = True,
            linewidths=0.5,
            linecolor="black",
            fmt = ".0f",
            cmap="YlGnBu",
            ax=ax)
plt.xlabel("True label")
plt.ylabel("Predicted label")
ax.set_title('RFC')
plt.show()
```

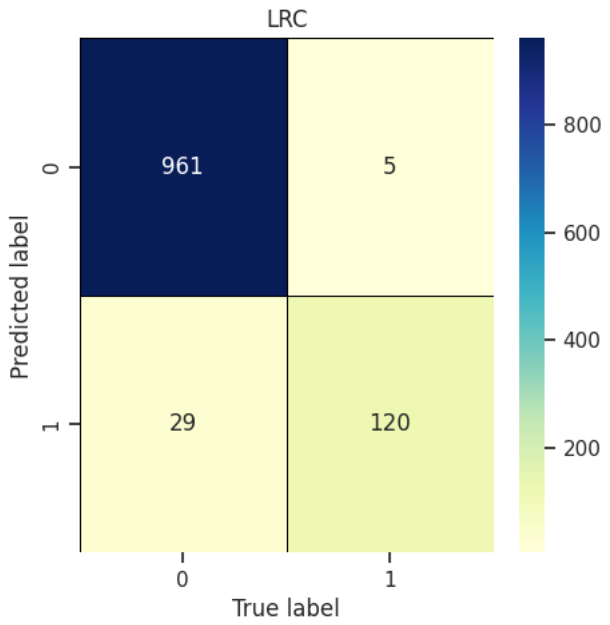

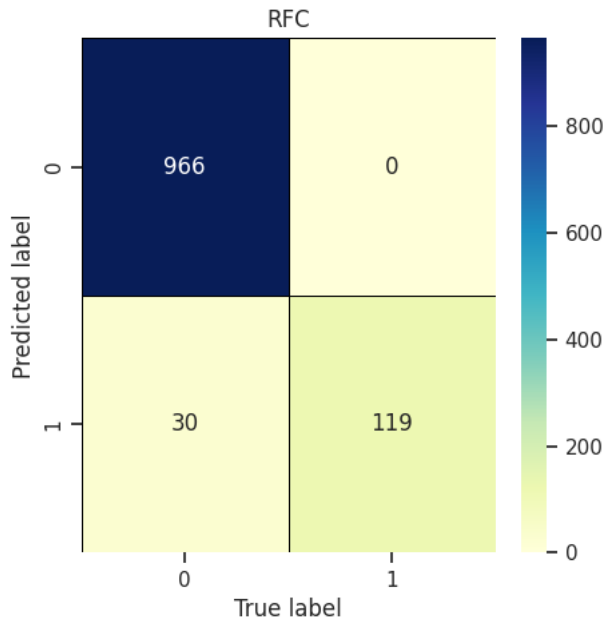

Comparaison des models

```
Classifier = [svc, knc,  mnb,dtc, lrc, rfc]
Accuracy=(accuracy_score(y_test,y_pred_SVC),
            accuracy_score(y_test,y_pred_KNC),
            accuracy_score(y_test,y_pred_MNB),
            accuracy_score(y_test,y_pred_DTC),
            accuracy_score(y_test,y_pred_LRC),
            accuracy_score(y_test,y_pred_RFC))
```

```
df = pd.DataFrame( Accuracy,
             index =  ["svc", "knc",  "mnb","dtc",
              "lrc", "rfc"])
df = df.reset_index()
df=df.rename(columns={0:"Valeur", "index":"Model"}) # Renommer le
df
```

	Model object	Valeur float64

0	svc	0.9793721973	
1	knc	0.9524663677	
2	mnb	0.9775784753	
3	dtc	0.9632286996	
4	lrc	0.9695067265	
5	rfc	0.9730941704	

6 rows, showing 10 per page « ‹ Page 1 of 1 › »

```
fig = plt.figure(figsize=(14, 10))
orderedA= df.sort_values(by='Valeur')# ordination
sns.set_theme(style="whitegrid")
sns.barplot(x="Valeur",y="Model",data=orderedA)
plt.xlim([0.9, 1])
plt.xlabel('Accuracy')
plt.ylabel('')
plt.title('Classifier Accuracy')
plt.show()
```

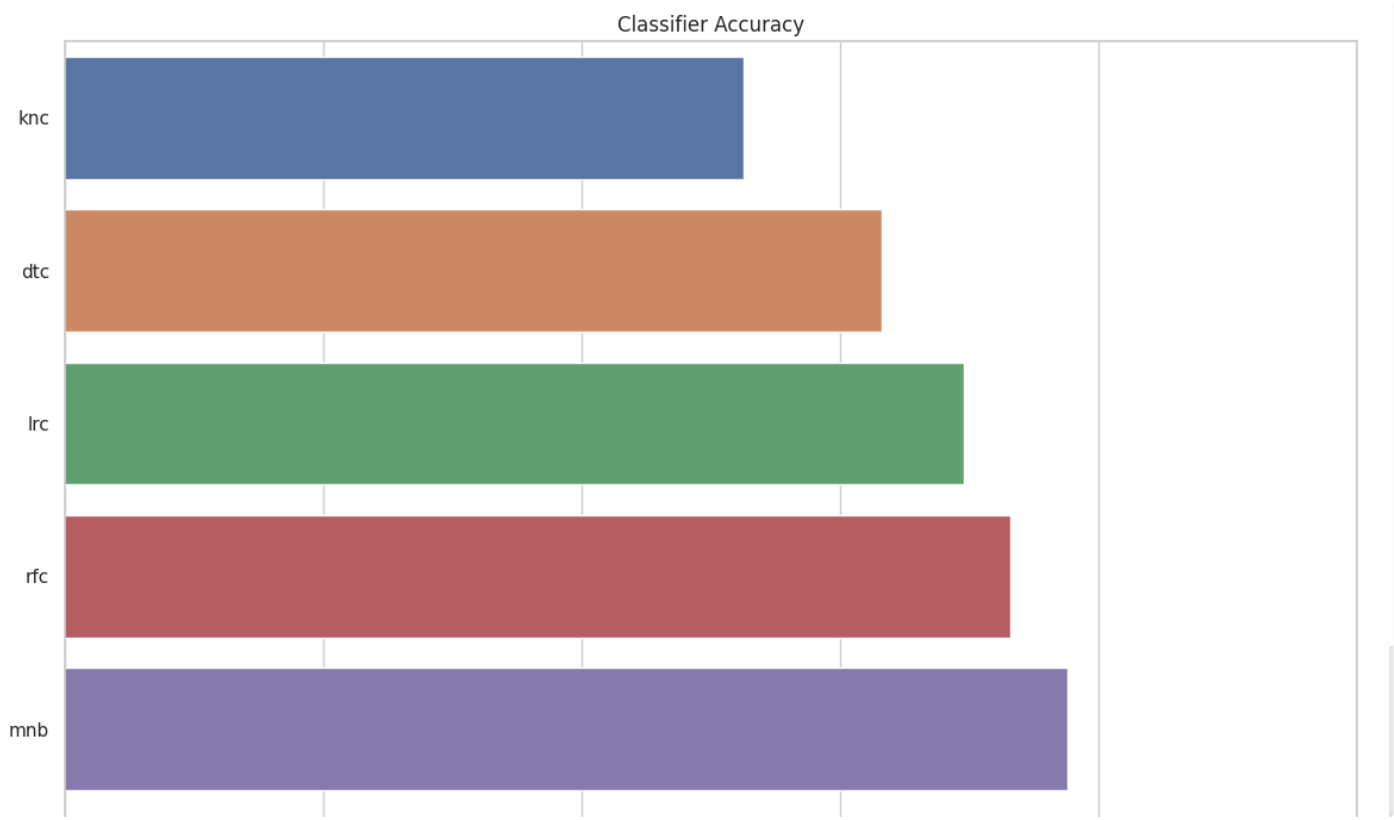

Cross Validation & Grid Search pour le Machine Learning

Amélioration des deux meilleurs modèles avec GridCV.

```
data1 = pd.read_csv('https://raw.githubusercontent.com/remijul/dataset/master/SMSSpamCollection',
         sep='\t', header=None)
data1=data1.rename(columns={0:"Target",1:"SMS"}) # Renommer les colonnes.
```

```
from sklearn import svm
from sklearn.naive_bayes import MultinomialNB
from sklearn.model_selection import GridSearchCV # importation du package GridSearchCV

# Categorical variables
from sklearn.compose import ColumnTransformer
```

Nous labellisons les features et la target, puis nous divisons le data set en train set et test set.

```
X=data1.drop('Target',axis=1) # serie
y=data1['Target']# serie
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
                                                    random_state=0,stratify=y)
```

Les deux modèles étudiés :

Support Vector Machine : SVC

Multinomial naive Bayes algorithm : mnb

```
svc = svm.SVC(kernel= 'sigmoid', gamma=1.0)
mnb = MultinomialNB()
```

Les paramètres :

```
parameters = {'model__kernel':['sigmoid','linear'],
              'model__C':[5,6,7,8]} # C-Support Vector Classification
```

```
alphas = [0.1,  0.3,  0.5,  0.7,  0.9, 1.0]
parameters_mnb = {'model__alpha': alphas, 'model__fit_prior' : [True, False]}
```

Transformer et pipelines :

```
transformer = ColumnTransformer(
    transformers=[
        (
        'data_vectorisation',TfidfVectorizer(use_idf=False,
                                             lowercase=True,
                                              strip_accents='ascii',
                                             stop_words=stop_words),
         'SMS')
    ])
```

```
pipe = Pipeline(steps =[
                        ('vectorizer', transformer), #
                        ('model', svc)
     ])
```

```
pipe_mnb = Pipeline(steps =[
                        ('vectorizer', transformer), #
                        ('model', mnb)
     ])
```

GridSearch fit

```
clf = GridSearchCV(pipe, parameters) #
```

```
clf_mnb = GridSearchCV(pipe_mnb, parameters_mnb) #
```

```
pipe.fit(X_train,y_train)
```

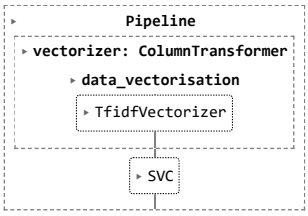


```
pipe_mnb.fit(X_train,y_train)
```

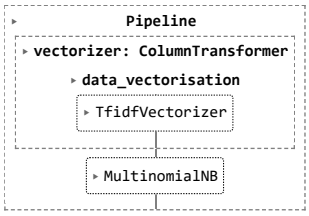


```
clf.fit(X_train, y_train)
```

```
clf_mnb.fit(X_train, y_train)
```

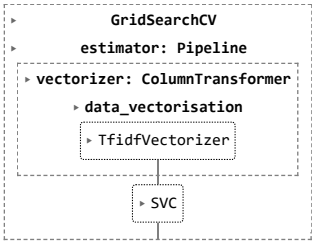

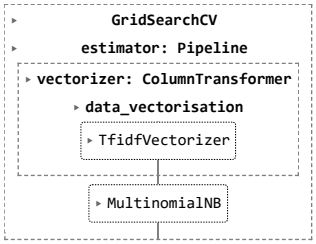


```
grid = GridSearchCV(pipe, parameters, cv = 5, n_jobs =-1, verbose
```

```
grid_mnb = GridSearchCV(pipe_mnb, parameters_mnb, cv = 5, n_jobs =
```

```
grid.fit(X_train, y_train)
```

```
Fitting 5 folds for each of 8 candidates, totalling 40 fits
```

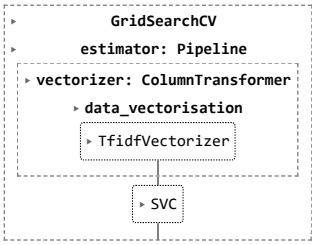


```
grid_mnb.fit(X_train, y_train)
```

```
Fitting 5 folds for each of 12 candidates, totalling 60 fits
```

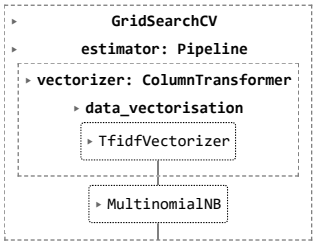


```
grid.get_params().keys()
```

```
dict_keys(['cv', 'error_score', 'estimator__
```

```
grid_mnb.get_params().keys()
```

```
dict_keys(['cv', 'error_score', 'estimator__
```

Resultats

```
sorted(grid.cv_results_.keys())
```

```
['mean_fit_time',
 'mean_score_time',
 'mean_test_score',
 'param_model__C',
 'param_model__kernel',
 'params',
 'rank_test_score',
 'split0_test_score',
 'split1_test_score',
 'split2_test_score',
 'split3_test_score',
 'split4_test_score',
 'std_fit_time',
 'std_score_time',
 'std_test_score']
```

```
sorted(grid_mnb.cv_results_.keys())
```

```
['mean_fit_time',
 'mean_score_time',
 'mean_test_score',
 'param_model__alpha',
 'param_model__fit_prior',
 'params',
 'rank_test_score',
 'split0_test_score',
 'split1_test_score',
 'split2_test_score',
 'split3_test_score',
 'split4_test_score',
 'std_fit_time',
 'std_score_time',
 'std_test_score']
```

```
grid.best_score_
```

```
0.9863140623977694
```

```
grid_mnb.best_score_
```

```
0.992446927343883
```

```
grid.best_params_
```

```
{'model__C': 5, 'model__kernel': 'linear'}
```

```
grid_mnb.best_params_
```

```
{'model__alpha': 0.1, 'model__fit_prior':
```

```
print(f"Le best score est : {grid_mnb.best_score_:.3f}")
```

```
Le best score est : 0.992
```

Conclusion :

Ici, le meilleur modèle est le Multinomial naive Bayes algorithme, avec un parametre alpha de 0.1.

Prédictions

Nous allons ici utiliser le model ayant le meilleur résultat : SVC

```
print ('Veuillez entrer votre sms suspect : ')
new_sms =input()
```

```
Veuillez entrer votre sms suspect :
```

```
prediction = SVC_vectorizer.predict([new_sms])

if prediction[0] == "spam":
    print("This sms is spam.")
else:
    print("This sms is not spam.")
```

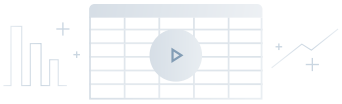

Run the app to see the outputs
Press the run button in the top right corner